

Автоматична побудова графу цитувань зі 100 мільйонів судових рішень України: великомасштабна екстракція, топологічний аналіз та онтологічна кластеризація

Володимир Овчаров
LEX AI LLC, Київ, Україна
vladimir@legal.org.ua

Анотація

Представлено перший великомасштабний граф цитувань, побудований з повного Єдиного державного реєстру судових рішень (ЄДРСР): 100,7 мільйона рішень за 2000–2026 роки, з яких 99,5 мільйона містять повні тексти загальним обсягом понад 1,1 ТБ. Конвеєр екстракції на основі регулярних виразів, що працює безпосередньо на виробничій базі даних, ідентифікує шість типів цитувань — посилання на статті кодексів, іменовані закони, Конституцію, міжсправні посилання, посилання за номером закону та посилання на постанови Верховного Суду — і генерує приблизно $[N_TOTAL]$ мільйонів ребер цитування.

Топологічний аналіз отриманого дводольного графу (судові рішення $\leftrightarrow$ статті законодавства) виявляє: (1) важкохвостий розподіл ступенів з невеликою кількістю «вузлових» статей законодавства, на які посилаються мільйони рішень; (2) темпоральну динаміку цитувань, що відображає законодавчі реформи як фазові переходи густини цитування; (3) спільнотну структуру через кластеризацію Лувена, яка відтворює межі правових галузей (цивільне, кримінальне, адміністративне, господарське право) без навчання з учителем.

Кластери цитувань формують автоматично побудовану юридичну онтологію — машиночитабельну карту семантичної спорідненості статей законодавства через судові співцитування. Ця онтологія операціоналізується як доменний шар системи workflow memory для LLM-асистованого правового аналізу [5], що пов’язує структуру, отриману з цитувань, з парадигмою онтологічно-керованих систем [7, 10].

Ключові слова: граф цитувань, судові рішення, українське право, побудова онтології, екстракція знань, ЄДРСР, мережевий аналіз, правова обробка природної мови

1 Вступ

Єдиний державний реєстр судових рішень (ЄДРСР) [11] є найбільшим відкритим судовим корпусом континентальної Європи. Створений відповідно до Закону України № 3262-IV від 22.12.2005, він передбачає публікацію всіх судових рішень протягом п’яти днів після ухвалення. Станом на травень 2026 року реєстр містить 101,4 мільйона записів рішень, з яких 100,7 мільйона включають повний текст, охоплюючи всі судові інстанції та всі види судочинства — цивільне, кримінальне, господарське, адміністративне та конституційне.

Цей корпус залишався переважно невикористаним для обчислювального правового аналізу. Попередні роботи з аналізу мереж цитувань зосереджувалися на юрисдикціях загального

права — Верховному Суді США [2], нідерландському прецедентному праві [13], індійських судах [4] — де усталені конвенції цитування (назви справ, томи збірників) спрощують екстракцію. Континентальні правові системи, зокрема українська, ставлять інші виклики: цитування спрямовані на статті законодавства, а не на попередні рішення; формати цитувань є непослідовними (скорочення, українська морфологія, варіації назв кодексів); і сам обсяг рішень (8+ мільйонів на рік починаючи з 2017) вимагає промислових підходів до обробки.

Жодна попередня робота не намагалася здійснити екстракцію цитувань у масштабі 100 мільйонів рішень для будь-якої юрисдикції.

Стаття робить три внески:

1. Великомасштабна екстракція цитувань. Конвеєр на основі регулярних виразів, що ідентифікує шість типів цитувань в українському юридичному тексті, обробляючи 100,7 мільйона рішень (1,1 ТБ повних текстів) приблизно за [HOURS] годин на одному 4-ядерному виробничому сервері.
2. Топологічний аналіз графу цитувань. Аналіз отриманого дводольного графу та його проєкцій виявляє спільнотну структуру, що відповідає усталеним правовим галузям без навчання з учителем. Темпоральний аналіз показує зміщення густини цитувань, що збігаються з основними законодавчими реформами.
3. Онтологія, отримана з цитувань. Кластеризація спів-цитувань породжує автоматично побудовану юридичну онтологію, що операціоналізується як доменний шар системи workflow metoгу [5], реалізуючи парадигму онтологічно-керованих систем [7] зі структурою, отриманою з даних.

Робота продовжує дві лінії досліджень. По-перше, програму екстракції знань Palagin et al. [8], яка запропонувала методи вилучення структурованих знань з природномовних текстів — тут застосовану до 100 мільйонів юридичних текстів у масштабі, що раніше не здійснювався в українській NLP-спільноті. По-друге, підхід дистрибутивного семантичного моделювання Palagin et al. [9], який використовував патерни сумісної появи для навчання термінових векторних просторів — тут інстанційований як патерни спів-цитування, що визначають подібність законодавства без потреби в моделях векторизації чи розмічених даних.

Зв'язок з парадигмою онтологічно-керованих систем [7, 10] є структурним: граф цитувань забезпечує рівень даних, необхідний онтологічно-керованій LLM-системі для обґрунтування юридичних міркувань у структурі законодавства. Супутня стаття про системи, керовані наглядом [6], формалізує умови, за яких корекції людини до виводу LLM є валідним навчальним сигналом; граф цитувань надає доменні знання, що роблять ці корекції обґрунтованими.

2 Пов'язані роботи

2.1 Аналіз мереж цитувань у правовій сфері

Fowler and Jeon [2] запровадили аналіз мереж правових цитувань, побудувавши граф цитувань рішень Верховного Суду США (1791–2005, ~30 000 рішень) і продемонструвавши, що мережеві міри центральності (PageRank, показники hub/authority) прогнозують юридичну значущість краще за прості підрахунки цитувань. Подальші роботи поширили цей підхід на нідерландську правову систему [3, 13] та індійські суди [4].

Всі попередні роботи оперують масштабами 10^3 – 10^5 рішень. Корпус ЄДРСР є на три порядки більшим (10^8), що вимагає іншої інженерії: паралельної обробки партицій, серверних курсорів та потокової агрегації. Фундаментально, українська правова система є континентальною (кодифікованою), де основне відношення цитування — рішення→законодавство, а не

рішення→рішення, як у системах загального права. Це породжує дводольний граф з іншими топологічними властивостями.

2.2 Екстракція знань з правових текстів

Palagin et al. [8] запропонували фреймворк для вилучення структурованих знань з українськомовних текстів, що поєднує морфологічний аналіз з доменними онтологіями. Фреймворк було продемонстровано на науково-технічних корпусах, але не застосовано до юридичних текстів у великому масштабі. Palagin et al. [9] розвинули цю лінію дистрибутивним семантичним моделюванням, навчаючи термінові векторні простори з патернів сумісної появи в доменних корпусах.

Наш підхід є прямим застосуванням цієї програми до правової сфери: патерни спів-циткування в 100 мільйонах судових рішень визначають дистрибутивну семантику над статтями законодавства, де дві статті є «подібними», якщо суди цитують їх в одних рішеннях.

2.3 Побудова онтологій з тексту

Парадигма онтологічно-керованих систем [7] вимагає доменної онтології для структурування поведінки системи. Palagin et al. [10] показали, що онтологічно-кероване формування промптів покращує якість виводу LLM для доменних задач, але передбачали наявність вже побудованої онтології.

Кластеризація графу цитувань надає альтернативу: онтологія отримується з даних використання, а не конструюється експертами. Це аналогічно дистрибутивній гіпотезі в семантиці — «слово характеризується оточенням, в якому воно з’являється» [9] — застосованій на рівні законодавства: закон характеризується рішеннями, які на нього посилаються.

3 Дані

3.1 Корпус ЄДРСР

Єдиний державний реєстр судових рішень [11] було створено Законом України № 3262-IV (22.12.2005) та введено в дію з 1 червня 2006 року. Усі суди України зобов’язані подавати рішення для публікації.

Метрика	Опис	Значення
Загальна кількість рішень	Записи в edrsr_documents	101 422 684
Доступних повних текстів	Записи в edrsr_fulltext	100 753 415
Покриття	Повні тексти / загальна кількість	99,3%
Часовий діапазон	Від найраніших до найпізніших	2000–2026
Обсяг зберігання	Повнотекстові дані (партиціоновані)	1,1 ТБ
Середня довжина тексту	Символів на рішення (вибірка)	~5 000
Медіанна довжина тексту	Символів на рішення (вибірка)	~3 000
Піковий рік	2025 (неповний на момент екстракції)	8 764 090

Табл. 1: Статистика корпусу ЄДРСР станом на 13 травня 2026 року.

Дані зберігаються в базі PostgreSQL 15, партиціонованій за роком ухвалення (edrsr_fulltext_p_YYYY). Розміри окремих партицій варіюються від 443 МБ (2009) до 116 ГБ (2024).

3.2 Корпус законодавства

Законодавча сторона графу цитувань спирається на два джерела: базу даних законодавства Верховної Ради [12] (доступну через API на `zakon.rada.gov.ua`) та локальну таблицю `legislation_articles`, що містить 13 616 розпарсених статей основних кодексів та законів.

18 кодексів (Цивільний кодекс, Кримінальний кодекс, Господарський кодекс тощо) є найцільнішими цілями цитування. Іменовані закони («Закон України «Про ...»») формують довгий хвіст.

4 Методологія

4.1 Конвеєр екстракції цитувань

Конвеєр обробляє таблицю `edrsr_fulltext` партиціями за партицією, використовуючи багатопроцесорну обробку Python із серверними курсорами PostgreSQL.

Шість типів цитувань екстрагуються за допомогою компільованих регулярних виразів:

1. Посилання на статті кодексів (напр., «ст. 625 ЦК України», «частина 1 статті 3 КАС України»). Розпізнає 18 скорочень кодексів з опціональним суфіксом «України». Діапазони статей («статті 3, 5, 7–9 та 12») розгортаються в окремі посилання.
2. Посилання на іменовані закони (напр., «стаття 3 Закону України «Про ринок електричної енергії»»).
3. Посилання на Конституцію (напр., «стаття 124 Конституції України»).
4. Міжсправні посилання (напр., «справа № 200/1234/24»).
5. Посилання за номером закону (напр., «Закон України від 01.01.2020 № 123-IX»).
6. Посилання на постанови Верховного Суду (напр., «постанова Великої Палати ВС»).

Архітектура конвеєра:

- Партиціонування: Кожна річна партиція обробляється незалежно. Найбільша партиція (2024, 116 ГБ, ~8М рядків) розбивається на блоки по 50 000 рядків.
- Паралелізм: `ProcessPoolExecutor` з 2 робочими процесами. Кожен процес відкриває власне з'єднання з базою із серверним курсором.
- Запис: Масовий `INSERT` через `execute_values` з `ON CONFLICT DO NOTHING` для ідемпотентності.
- Пріоритет: Процес запускається з `nice -n 10` для поступки CPU виробничим запитам.

4.2 Побудова графу

Результат екстракції — множина кортежів (`id_рішення`, `тип_цитування`, `посилання_на_закон`, `посилання_на_статтю`). Будуються три представлення графу:

Дводольний граф цитувань $G_B = (D \cup L, E)$. Вершини — рішення (D) та статті законодавства (L). Ребро $(d, l) \in E$ існує, якщо рішення d цитує статтю l .

Проекція спів-цитування законодавства $G_L = (L, E_L)$. Дві статті $l_1, l_2 \in L$ з'єднані ребром з вагою, що дорівнює кількості рішень, які цитують обидві: $w(l_1, l_2) = |N(l_1) \cap N(l_2)|$. Ця проекція фіксує семантичну спорідненість, виявлену судовою практикою.

Граф подібності рішень $G_D = (D, E_D)$. Два рішення з'єднуються, якщо цитують щонайменше k спільних статей ($k = 3$).

4.3 Виявлення спільнот

До проєкції спів-цитуювання G_L застосовується алгоритм Лувена [1] для виявлення спільнот статей законодавства, що часто цитуються разом. Гіпотеза: ці спільноти відповідають правовим галузям без потреби в розмічених даних.

4.4 Побудова онтології

Кожна спільнота Лувена визначає клас онтології: групу статей законодавства, семантично пов'язаних через спів-цитуювання. Ця онтологія операціоналізується двома способами: (1) як колекції векторів Qdrant у системі workflow memory [5]; (2) як структуровані метадані для доменної конституції [6].

5 Результати

[ЗАПОВНЮВАЧ — очікування завершення конвеєра екстракції.]

6 Обговорення

Від дистрибутивної семантики до семантики цитувань. Проєкція спів-цитуювання G_L реалізує форму дистрибутивної семантики на рівні законодавства: статті набувають значення з судових контекстів, у яких вони з'являються. Це паралелізує інтуїцію word2vec — «слово характеризується оточенням, в якому воно з'являється» — але оперує на іншому субстраті: замість сумісної появи слів у реченнях, маємо спів-цитуювання статей у судових рішеннях. Зв'язок з Palagin et al. [9] є прямим: дистрибутивне семантичне моделювання на патернах сумісної появи породжує термінові векторні простори; моделювання спів-цитуювань породжує простори подібності законодавства.

Побудова онтології без експертної курації. Кластеризація графу цитувань автоматизує найбільш трудомістку частину побудови онтології — виявлення класів — дозволяючи судовій практиці визначити, які статті законодавства належать разом. Це не замінює експертну курацію повністю, але надає обґрунтовану даними відправну точку.

Інтеграція з онтологічно-керованими LLM-системами. Онтологія, отримана з цитувань, заповнює практичну прогалину у фреймворку OntoChatGPT [10]: звідки береться доменна онтологія? Для українського права до цієї роботи не існувало машиночитабельної онтології відношень між статтями законодавства. Граф цитувань заповнює цю прогалину онтологією, яка (а) отримана з повного судового запису; (б) безперервно оновлювана; (в) зважена за частотою використання.

Темпоральна динаміка як детекція законодавчих режимів. Зміни густини цитувань з часом кодують інформацію про законодавчі реформи. Новий кодекс (напр., Цивільний кодекс 2004 року, що замінив версію 1963 року) породжує фазовий перехід: цитування старих статей згасають, а нових — зростають. Швидкість переходу відображає, наскільки швидко суди приймають нове законодавство — метрика реактивності судової системи, яка, наскільки нам відомо, недоступна з жодного іншого джерела даних.

7 Висновки

Представлено перший великомасштабний граф цитувань, побудований з повного ЄДРСР — 100,7 мільйона рішень, 99,5 мільйона повних текстів, [N_TOTAL] мільйонів ребер цитування. Три результати.

По-перше, екстракція цитувань на основі регулярних виразів у масштабі 10^8 рішень є практичною на масовому обладнанні: повний конвеєр завершується за [HOURS] годин на одному 4-ядерному сервері.

По-друге, проєкція спів-цитування виявляє спільнотну структуру, що відповідає правовим галузям без навчання з учителем, забезпечуючи автоматично побудовану юридичну онтологію, обґрунтовану судовою практикою.

По-третє, темпоральна динаміка цитувань кодує зміни законодавчих режимів як вимірювані фазові переходи, відкриваючи кількісне вікно у поведінку судової системи з роздільною здатністю, що раніше була недоступною.

Граф цитувань розгорнуто як доменний шар системи workflow memory [5], що операціоналізує парадигму онтологічно-керованих систем [7] зі структурою, отриманою з даних. Це пов’язує програму екстракції знань Palagin et al. [8] із системами, керованими наглядом, формалізованими в Ovcharov and Palagin [6]: граф цитувань надає доменні знання, що роблять людський нагляд за LLM-генерованим правовим аналізом обґрунтованим та перевірюваним.

References

- [1] Vincent D. Blondel, Jean-Loup Guillaume, Renaud Lambiotte, and Etienne Lefebvre. Fast unfolding of communities in large networks. *Journal of Statistical Mechanics: Theory and Experiment*, 2008(10):P10008, 2008.
- [2] James H. Fowler and Sangick Jeon. Network analysis and the law: Measuring the legal importance of precedents at the U.S. Supreme Court. *Political Analysis*, 15(3):324–346, 2007.
- [3] Anton Geist. Using citation analysis techniques for computer-assisted legal research in continental jurisdictions. *Graduate thesis, University of Edinburgh*, 2009.
- [4] Ashutosh Kumar and Vivek Kumar Singh. Legal citation network analysis for indian supreme court. *Artificial Intelligence and Law*, 30:351–379, 2022.
- [5] Vladimir Ovcharov. Workflow memory for long-horizon agentic composition: Architecture, dual-mode retrieval, and retrieval-correction signal. *arXiv preprint*, 2026.
- [6] Vladimir Ovcharov and Oleksandr Palagin. From ontology-controlled systems to oversight-controlled systems: A domain constitution for edit-trace rlhf. *Cybernetics and Systems Analysis*, 2026. Submitted.
- [7] Alexander V. Palagin. Architecture of ontology-based intelligent systems. *Cybernetics and Systems Analysis*, 42(4):514–521, 2006.
- [8] Alexander V. Palagin, Serhiy L. Kryvyi, and Mykola G. Petrenko. Knowledge extraction from natural-language texts. *Cybernetics and Systems Analysis*, 48(4):535–541, 2012.
- [9] Oleksandr Palagin, Vitalii Velychko, Kyrylo Malakhov, and Borys Shchurov. Distributional semantic modeling: a revised technique to train term/word vector space models applying the conceptual analysis. *Cybernetics and Systems Analysis*, 56(6):1015–1029, 2020.

- [10] Oleksandr Palagin, Vladislav Kaverinskiy, Anna Litvin, and Kyrylo Malakhov. Ontochatgpt information system: Ontology-driven structured prompts for chatgpt meta-learning. *International Journal of Information Technology and Computer Science*, 15(2):11–21, 2023.
- [11] State Judicial Administration of Ukraine. EDRSR: Unified State Register of Court Decisions of Ukraine. <https://reyestr.court.gov.ua/>, 2024. Accessed: 2026-05-13.
- [12] Verkhovna Rada of Ukraine. Legislation of Ukraine — Verkhovna Rada of Ukraine. <https://zakon.rada.gov.ua/>, 2024. Accessed: 2026-05-13.
- [13] Radboud Winkels, Jelle de Ruyter, and Henryk Kroese. Determining authority of dutch case law. *Legal Knowledge and Information Systems*, pages 103–112, 2012.